TP INTEGRADOR · MÉTODOS PREDICTIVOS PARA LA GESTIÓN

Análisis exploratorio y descriptivo

Puntos 3.1 a 3.6 · guía para la exposición

Datos: Online News Popularity (UCI) — 39.643 artículos publicados por Mashable, con 44 variables cuantitativas y la variable objetivo **shares** (cantidad de veces que se compartió cada artículo).

Pregunta que guía el trabajo: ¿qué características de un artículo se asocian con que se comparta más?

Idea de esta etapa: antes de construir cualquier modelo, conocer los datos. Mirar cómo es lo que queremos predecir, cómo son las variables que usaremos para predecirlo, cómo se relacionan entre sí y cuáles se repiten.

Punto	Qué se hizo	Para qué sirve
3.1	Estadísticos descriptivos	Conocer escalas, rangos y extremos de las variables
3.2	Análisis de la variable objetivo (shares)	Entender qué vamos a predecir y cómo tratarlo
3.3	Distribución de las variables	Ver la forma de cada variable y cuáles necesitan transformación
3.4	Relaciones entre variables	Detectar si algo se mueve junto con shares o entre predictores
3.5	Correlación y multicolinealidad	Medir la asociación con shares y evitar variables repetidas
3.6	Principales hallazgos	Resumir lo aprendido y dejar listo el paso al modelado

En una frase: la popularidad de un artículo es muy desigual (unos pocos se comparten muchísimo), ninguna variable por sí sola la explica, y varias variables son casi copias entre sí. Por eso el modelo trabajará con *shares* en escala logarítmica y con un conjunto de variables depurado.

PUNTO 3.1

Estadísticos descriptivos

Resumen numérico de las variables

Qué se hizo	Se calculó, para las 44 variables cuantitativas y para *shares*, la media, el desvío, el mínimo, los cuartiles y el máximo. Luego se eligieron 9 variables de interés que cubren cuatro dimensiones del artículo: extensión, enlaces y multimedia, organización temática, y sentimiento.
Por qué	Antes de modelar hay que saber con qué se trabaja. Con 44 variables no se puede mirar todo en detalle, así que se elige un subconjunto fácil de interpretar para el análisis visual.
Para qué	Detectar escalas muy distintas, diferencias entre media y mediana (señal de asimetría) y valores extremos, para decidir cómo preparar los datos.

Las 9 variables de interés

Variable	Dimensión	Media	Mediana	Máximo
n_tokens_content	Extensión	546,5	409	8.474
average_token_length	Extensión	4,55	4,66	8,04
num_hrefs	Enlaces y multimedia	10,9	8	304
num_imgs	Enlaces y multimedia	4,5	1	128
num_videos	Enlaces y multimedia	1,25	0	91
num_keywords	Temática	7,2	7	10
kw_avg_avg	Temática	3.136	2.870	43.568
global_sentiment_polarity	Sentimiento	0,119	0,119	0,728
title_subjectivity	Sentimiento	0,28	0,15	1,0

Fuente: tabla de estadísticos descriptivos del notebook (39.643 observaciones).

Resultado clave

- Las escalas son muy distintas: un título tiene en promedio ~10 palabras, mientras que *kw_max_max* promedia unos 752.000.
- En casi todas las variables de conteo la media supera a la mediana (por ejemplo, 4,5 imágenes de media contra 1 de mediana): hay pocos artículos con valores muy altos que "tiran" el promedio hacia arriba.

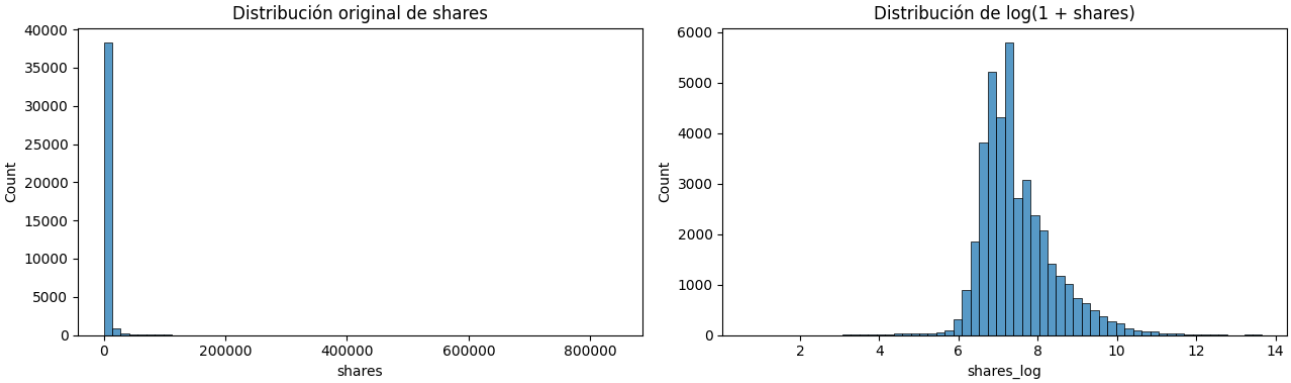
Conclusión del punto. los datos no están en la misma escala y presentan asimetría; hay que tenerlo presente al elegir transformaciones y al comparar coeficientes más adelante.

PUNTO 3.2

Análisis de la variable objetivo: shares

Qué queremos predecir

Qué se hizo	Se describió *shares* con sus estadísticos y percentiles, se la graficó (histogramas y boxplot), se aplicó el criterio de Tukey (rango intercuartílico) para marcar valores atípicos y se creó una versión transformada: **shares_log = log(1 + shares)**.
Por qué	Es la variable que el modelo debe predecir; si su forma es problemática, el modelo también lo será. Conviene entenderla bien antes de usarla.
Para qué	Decidir cómo tratarla en el modelado y cuál medida resume mejor el valor típico.



Izquierda: shares original (casi todo comprimido en el cero). Derecha: la misma variable en escala logarítmica, con forma de campana.

Resultado clave

- **Media 3.395 vs. mediana 1.400**: unos pocos artículos muy compartidos suben el promedio. La mediana describe mejor al artículo típico.
- El 50 % central de los artículos está entre **946 y 2.800** shares; el máximo es **843.300** (más de 600 veces la mediana). Coeficiente de asimetría ≈ 34.
- Límite de atípicos por Tukey: Q3 + 1,5 × RIC = 2.800 + 1,5 × 1.854 = **5.581**. Hay **203** artículos "ultra virales" (más de 50.000 shares).
- Esos valores **no se eliminan**: no hay evidencia de que sean errores, representan viralidad real.

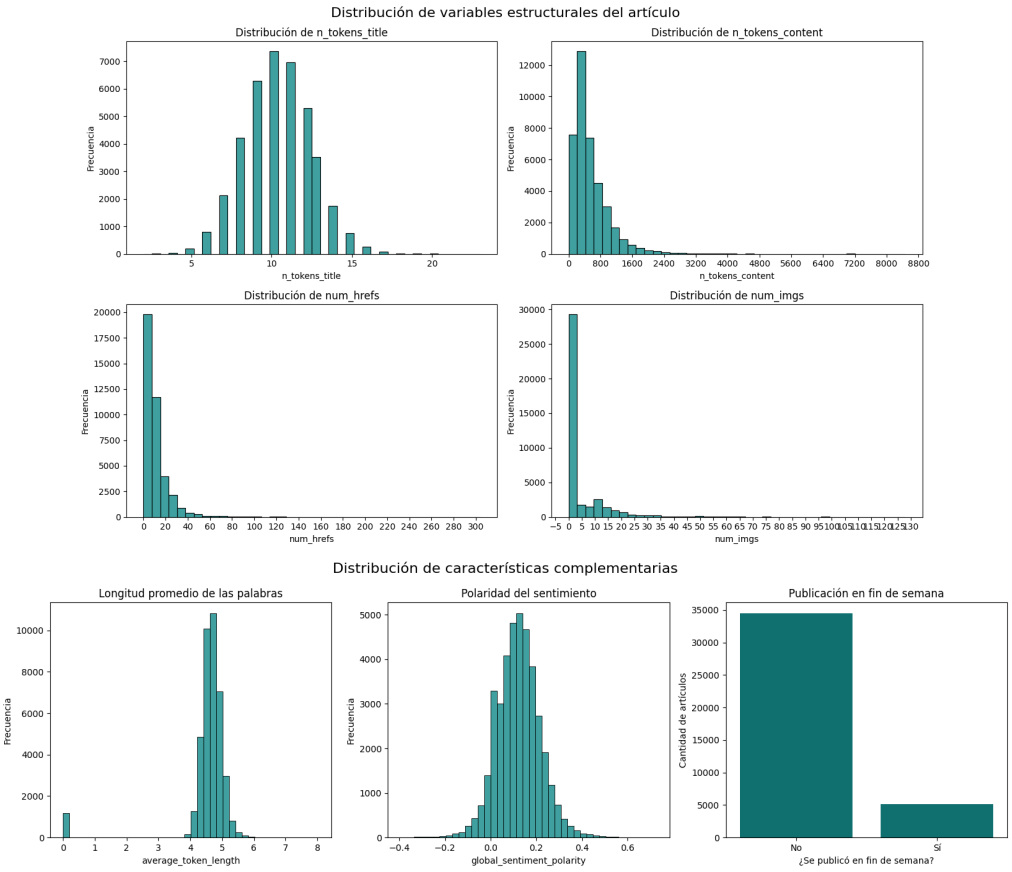
Conclusión del punto. *shares* está fuertemente sesgada a la derecha. Se modelará sobre *shares_log* (que se comporta como una campana) y se conserva la variable original para interpretar resultados en cantidad de compartidos.

PUNTO 3.3

Distribución de las variables

Cómo es cada predictora por separado

Qué se hizo	Se graficaron histogramas de las variables de estructura del artículo (título, contenido, enlaces, imágenes) y de características complementarias (longitud de palabras, polaridad del sentimiento y publicación en fin de semana). Las demás de las 9 variables se describen con sus estadísticos de 3.1.
Por qué	Un número resumen no muestra la forma. El histograma permite ver si una variable es simétrica, si tiene cola larga o si hay grupos raros.
Para qué	Identificar qué variables necesitan transformación y qué valores merecen revisión.



Resultado clave

- Título (*n_tokens_title*): casi simétrico, centrado en ~10 palabras. Es la variable más "bien portada".
- Contenido, enlaces e imágenes: **asimétricas a la derecha**. Mediana de 409 palabras, 8 enlaces y 1 imagen, con colas que llegan a 8.474 palabras, 304 enlaces y 128 imágenes.
- Polaridad del sentimiento: centrada en ~0,12 (tono levemente positivo). Se publica más en días de semana que en fin de semana.
- En *average_token_length* hay un grupo con valor 0: son los 1.181 artículos sin texto detectados en la sección 2.

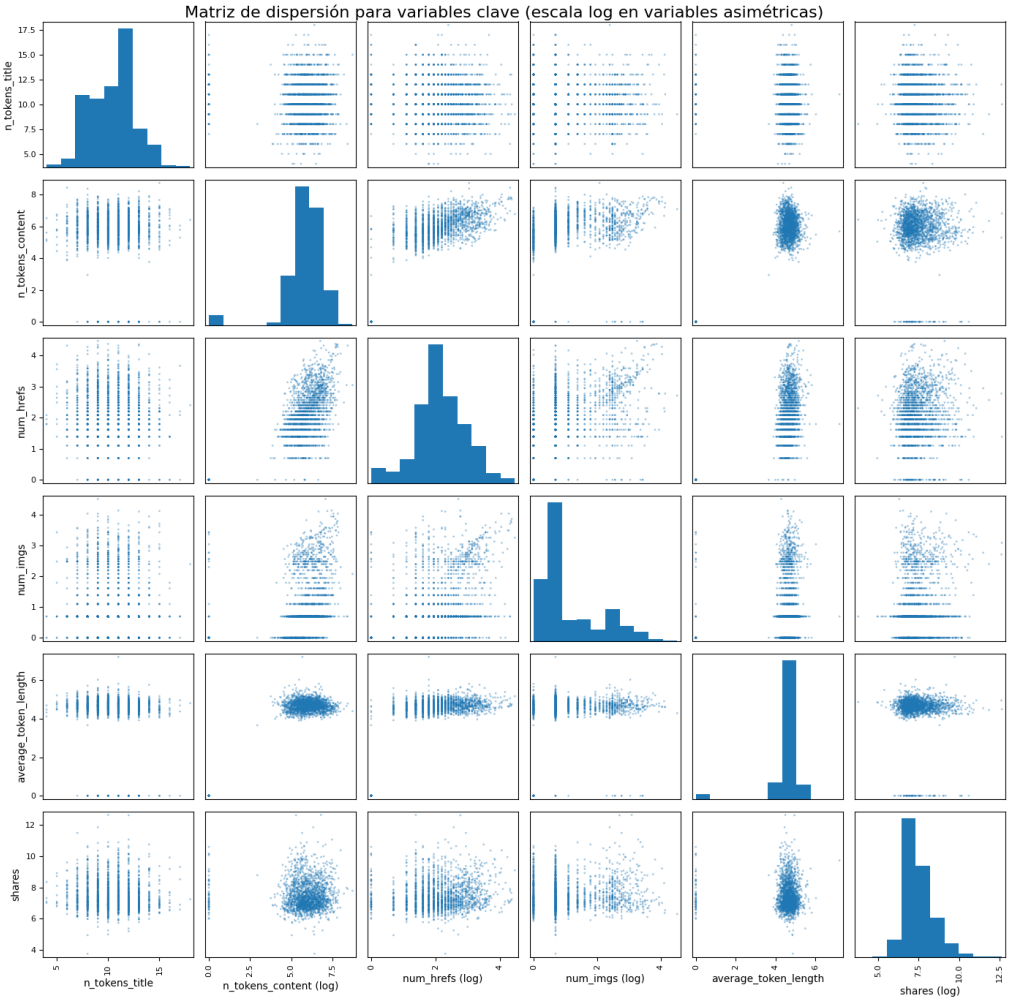
Conclusión del punto. las variables de conteo (palabras, enlaces, imágenes) son asimétricas y se beneficiarían de una transformación; los valores extremos se revisan, no se descartan automáticamente.

PUNTO 3.4

Relaciones entre variables

Cómo se mueven de a pares

Qué se hizo	Se armó una matriz de dispersión (gráficos de puntos de a pares) con 6 variables — título, contenido, enlaces, imágenes, longitud de palabras y *shares* — sobre una muestra de 2.000 artículos. Las variables asimétricas se graficaron en escala logarítmica.
Por qué	Sin el logaritmo, unos pocos valores extremos aplastan al resto de los puntos y no se ve nada. Con él, la nube se abre y se puede juzgar si hay relación.
Para qué	Ver si alguna variable acompaña a *shares* y si hay predictoras que se mueven juntas.



Resultado clave

- **Con shares no se ve ningún patrón claro**: los artículos más compartidos aparecen repartidos en todos los valores de cada variable.
- Entre predictoras sí hay una relación: los artículos más largos tienden a tener más enlaces e imágenes.
- *average_token_length* muestra el grupo de valor 0 ya señalado (artículos sin texto).

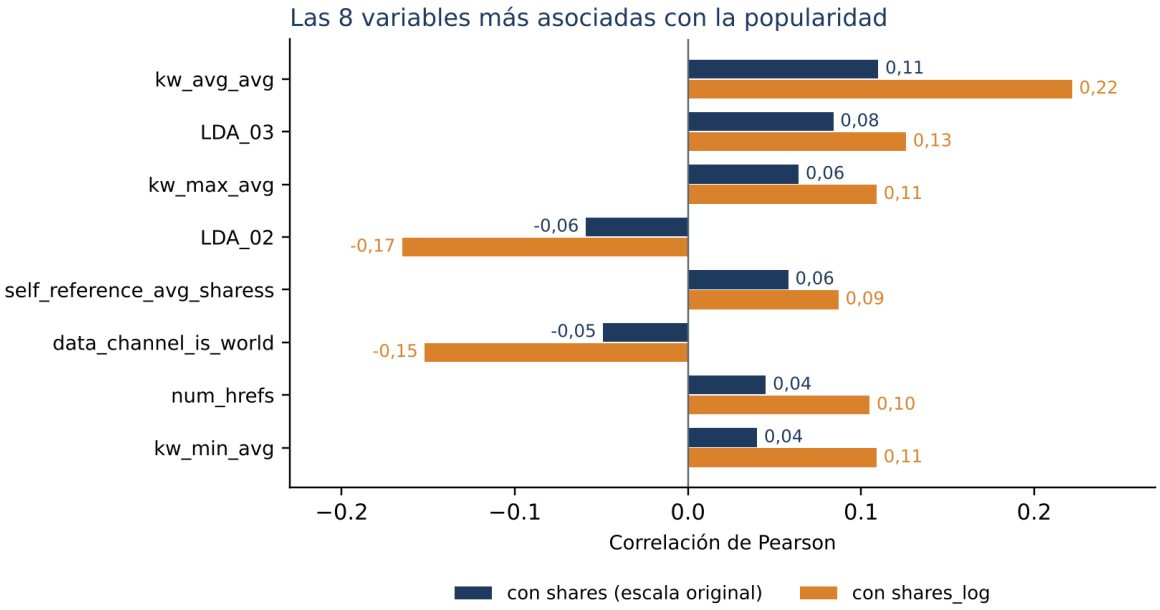
Conclusión del punto. a nivel individual, ninguna de estas variables explica por sí sola la popularidad; algunas predictoras se parecen entre sí.

PUNTO 3.5

Matriz de correlación

Qué tanto se asocia cada variable con shares

Qué se hizo	Se calculó la correlación lineal (Pearson) de cada variable con *shares* y con *shares_log*, se graficó el mapa de calor completo y uno acotado a las 9 variables de interés.
Por qué	La correlación resume en un número (de -1 a 1) cuánto se mueven juntas dos variables: cerca de 0 significa que casi no están relacionadas linealmente.
Para qué	Ordenar las variables por su asociación con la popularidad y comprobar si conviene la escala logarítmica.



Fuente: correlaciones calculadas sobre los 39.643 artículos.

Resultado clave

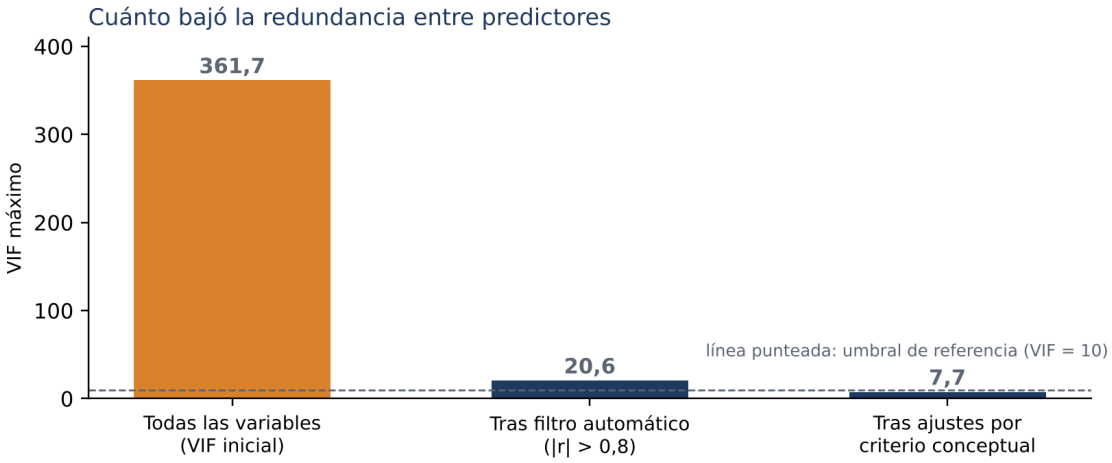
- Las asociaciones con *shares* son **muy débiles**: la mayor es *kw_avg_avg* con 0,11 (promedio de popularidad de las palabras clave del artículo).
- Con *shares_log* la señal casi se duplica (0,11 pasa a 0,22), lo que confirma que conviene modelar en escala logarítmica.
- Lo más asociado: popularidad previa de las palabras clave (*kw_**), referencias a artículos propios (*self_reference_**) y algunos temas (*LDA_03*, *LDA_02*).

PUNTO 3.5

Multicolinealidad entre predictoras

Qué variables se repiten entre sí

Qué se hizo	Se miró cuáles predictoras están muy correlacionadas entre sí y se midió con el **VIF** (factor de inflación de la varianza: cuánto una variable puede reconstruirse a partir de las otras). Se aplicó un filtro automático (correlación mayor a 0,8) y luego se revisó caso por caso.
Por qué	Si dos variables dicen casi lo mismo, el modelo no puede separar el efecto de cada una y sus coeficientes se vuelven inestables, aunque la predicción global pueda seguir siendo buena.
Para qué	Quedarse con un conjunto de variables candidatas sin repeticiones.



Grupo de variables repetidas	Qué se decidió
n_unique_tokens, *n_non_stop_words*, *n_non_stop_unique_tokens* (miden casi lo mismo)	Se conserva una; las otras salen
data_channel_is_world y *LDA_02* (r = 0,84)	No van juntas: se prueban por separado en el modelado
kw_avg_avg y *kw_max_avg* (r = 0,81)	Se conserva *kw_avg_avg* (mayor asociación con *shares_log*)
self_reference promedio, mínimo y máximo (r = 0,82 y 0,85)	Se conserva el promedio

Resultado clave

- Con todas las variables el VIF llega a **361,7** (redundancia extrema). El filtro automático lo baja a **20,6** y los ajustes por criterio conceptual a **7,7**.
- Tres variables que el filtro había eliminado se reincorporaron por ser las más interpretables de su grupo: *kw_avg_avg*, *self_reference_avg_sharess* y *data_channel_is_world*.

Conclusión del punto. hay bloques de variables casi duplicadas que no deben entrar todas juntas al modelo. Lo identificado son **candidatas iniciales**: la selección definitiva se hace en el modelado, con datos de entrenamiento, reservando el conjunto de prueba para la evaluación final.

PUNTO 3.6

Principales hallazgos del análisis exploratorio

Conclusión final

Lo que aprendimos, en cuatro ideas

1

La popularidad es muy desigual

La mayoría de los artículos se comparte poco (mediana 1.400) y unos pocos se comparten muchísimo (hasta 843.300). Por eso se modela *shares_log* y se conserva *shares* para interpretar.

2

Los predictores también son asimétricos

Palabras, enlaces e imágenes se concentran en valores bajos y tienen colas largas. Los extremos se revisan pero no se eliminan sin evidencia de error.

3

Ninguna variable explica sola la popularidad

Las correlaciones con *shares* son débiles (máximo 0,11; 0,22 con el logaritmo). Si hay capacidad predictiva, vendrá de combinar muchas variables.

4

Hay variables repetidas entre sí

Familias como *kw_**, *self_reference_** y *n_non_stop_** son casi duplicados. Se depuran para que el modelo sea estable y sus coeficientes interpretables.

Conclusión

El problema de predecir cuántas veces se comparte un artículo **no es trivial**. Los datos son muy asimétricos y las relaciones individuales con la popularidad son débiles, así que se espera un poder predictivo moderado y predicciones con margen de error. Esto justifica avanzar hacia un modelo de regresión múltiple sobre *shares_log*, con un conjunto de variables depurado de redundancias, antes de sacar conclusiones sobre cuán lineal es el fenómeno.

Qué sigue

Definir el problema predictivo y las hipótesis (sección 4), extraer la muestra aleatoria de 750 artículos y compararla con la población (sección 5), ajustar el modelo de regresión lineal (sección 6) y comparar con modelos de Machine Learning (secciones 7 y 8).